Tarea P — Temperatura, top-p y entropía (con datos personales)

MMIA 6013 · Tarea de práctica para el Taller 04 (guardrail de datos personales) Entrega: un notebook de Jupyter (`.ipynb`) **ejecutado**, con las salidas visibles.

Estudiante: Valeria Quinde Mora · correo valeria.quinde.ficticia@ejemplo.ec · C.I. 1704567890 · celular 0987654321. Pon estos datos en la primera celda del notebook.

Un modelo de lenguaje produce, para el siguiente token, un vector de *logits*. Considera un vocabulario de seis tokens, `t0` a `t5`, con estos logits:

Token	t0	t1	t2	t3	t4	t5
Logit	2.0	1.0	0.5	0.2	-1.0	-3.0

Parte 1 — Softmax con temperatura

Implementa en NumPy la función softmax con temperatura p_i = exp(z_i/T) / Σ_j exp(z_j/T), numéricamente estable. Calcula la distribución para T = 0.5, T = 1 y T = 2, y la **entropía en bits** de cada una. Presenta las tres distribuciones y las tres entropías en una tabla, con cuatro decimales.

Parte 2 — Muestreo de núcleo (top-p)

Con la distribución de T = 1 de la Parte 1, aplica top-p con p = 0.9: ordena los tokens por probabilidad, conserva el conjunto mínimo cuya probabilidad acumulada alcanza 0.9 y renormaliza. Reporta qué tokens sobreviven y la distribución renormalizada.

Parte 3 — Comprobación empírica

Toma 10 000 muestras de la distribución renormalizada de la Parte 2 con `numpy.random.default_rng(0)`. Compara las frecuencias observadas con las probabilidades teóricas en un gráfico de barras y calcula la divergencia KL (en bits) de la distribución empírica respecto de la teórica.

Parte 4 — Pregunta conceptual

Explica qué le pasa a la distribución cuando T → 0 y cuando T → ∞, y por qué T → 0 equivale a la decodificación voraz (*greedy*). Usa las entropías de la Parte 1 como evidencia.

Formato

Un solo notebook, ejecutado de principio a fin sin errores, con una celda de Markdown que encabece cada parte. Las cifras se calculan en el notebook, no se escriben a mano.